实验 6 工具调用、Agent 与 Harness 实现 实验报告

学习通提交说明

- 提交平台：只向学习通对应的作业上传一份 PDF 文件。
- 文件命名：班级-学号-姓名-实验 6-工具调用、Agent 与 Harness 实现.pdf。
- PDF 内容：任务说明、工具接口、Agent、Harness、执行日志和实验小结，附仓库链接与 Commit。
- 截止时间：以学习通作业设置为准。

1. 实验目的

- 掌握工具接口定义、参数验证、权限边界和结果反馈。
- 实现一个由模型根据任务和工具结果决定下一步操作、运行状态可查看且能够终止的单 Agent。
- 编写运行时 Harness，完成上下文组织、工具执行、结果检查、停止控制和日志记录。

2. 实验内容

2.1 任务选择与边界

- 结合个人软件选择一个范围较小、结果能够检查的任务，如查询样例数据后生成统计结果；不适合接入个人软件时，可独立完成练习。
- 列出任务目标、可用数据、工具、停止条件和成功标准，并给出一组输入及预期结果。本实验实现单 Agent，由模型根据目标和工具结果决定下一步操作；说明哪些步骤由程序预设，哪些由模型决定。
- 说明哪些操作允许自动执行，哪些必须用户确认，哪些明确禁止。

2.2 工具接口与参数约束

- 实现至少 2 个可实际运行的工具，如读取样例文件、查询数据或执行统计计算，说明名称、用途、输入字段、类型、必填项、返回结果和错误信息。输入格式及字段约束也称 Schema。
- 建立允许调用的工具列表，执行前由程序检查工具名称、参数和访问范围，例如数值范围、允许的文件目录或可访问的数据；不能直接执行模型生成的任意函数名或命令。
- 说明工具的最长等待时间、是否修改数据，以及重复调用是否会产生重复修改；在接入 Agent 前，直接测试至少一次正确参数和一次错误参数。

2.3 Agent 循环与状态

- 绘制“接收目标—模型提出调用请求—程序检查并执行工具—回传工具结果—模型继续或给出最终回答”的循环图，标出参数校验、人工确认和停止检查的位置。

- 接入支持工具调用的模型接口，或约定可由程序解析的 JSON 调用格式，实际运行模型与工具之间的循环。模型提出工具名称和参数，程序负责执行；将调用请求和对应工具结果按接口要求加入后续上下文，不能只把结果打印出来。
- 设置最大执行步数、模型与工具调用超时、总运行时限及重试上限，说明一步如何计数，并由程序执行限制。模型给出最终回答后，还应检查结果是否满足 2.1 的成功标准，不能仅凭模型声称完成就判定成功。

2.4 运行时 Harness 设计与实现

- 将组织模型与工具运行的外围程序作为本实验的运行时 Harness，说明任务输入、上下文、执行、结果检查和日志分别由哪些函数或模块负责，不要求拆成多个独立服务。
- 实现模型调用、工具分发、参数与权限检查、结果回传和停止控制；保留当前任务需要的输入、调用记录及工具结果。关键限制必须由程序执行，不能只写在提示词中。
- 工具失败或结果不符合要求时，将错误信息反馈给模型进行有限次修正，或结束任务并说明原因。可以使用开发框架或自行编写代码，但须说明实际控制流程，不要求多 Agent 或复杂框架。

2.5 失败处理与可观测性

- 为每次运行设置任务编号，记录时间、调用的工具与参数摘要、工具结果、错误类型、执行步数、耗时和最终状态；密钥和个人信息须遮挡或省略。
- 处理参数错误、工具异常、超时和达到步数上限等情况，返回明确状态和原因。超时可能只是停止等待，不代表后台工具已停止，应说明实际取消能力；可能修改数据的调用状态不明时，先核对执行结果，不得直接重试。
- 对需要确认的操作，在执行前展示操作内容与影响，由用户明确同意后执行；拒绝或等待超时则不执行。

2.6 测试与结果分析

- 至少测试 5 类情况：正常完成、参数错误、工具异常、达到步数或时间限制、人工确认。其中人工确认分别检查同意与拒绝；异常与边界情况可模拟触发，正常流程必须实际调用模型和工具。
- 用表格记录输入、预期行为、实际结果和判断依据，检查任务是否完成、错误是否正确反馈、停止与确认规则是否生效；未符合预期时，分析问题出在模型决策、参数、工具、检查规则还是控制流程。
- 说明 Agent 及运行时 Harness 是否用于个人软件，以及当前局限和改进计划；在个人 GitHub/Gitee 仓库保存工具、Agent、Harness、测试代码和运行说明，报告注明路径及对应 Commit。

3. 操作记录

本节按 2.1—2.6 的顺序记录实际操作：先说明做法，再给出表格、代码、截图和日志证据。截图均来自真实运行的前后端（Spring Boot 3.3.5，端口 8080；Vite，端口 5173；模型 qwen-plus），编号与正文一致。

实验环境：Windows，JDK 17.0.16，Maven 3.9.10，Node.js 24.16.0，H2 文件数据库，千问 qwen-plus（OpenAI 兼容 tools 接口）。

3.1 任务选择与边界

本实验在个人软件“AI 需求歧义审查器”上实现“审查档案分析助手”：用户用自然语言询问审查档案的风险情况，Agent 通过只读工具查询 H2 中的真实档案和内置知识库，给出数字可核对的结论；删除档案是唯一的写操作，用于验证人工确认。选择这个任务，是因为范围小、结果可判定（统计数字必须与数据库聚合一致），并且直接复用个人软件已有的数据，不需要另造样例。

表 3-1 任务卡

项目	内容
任务目标	用自然语言查询档案风险分布、单条档案详情和知识库规则，给出可核对的结论
典型提问	① 现在有多少份档案，风险分布如何？② 最近一条档案最严重的问题是什么？③ 知识库里文件上传有什么限制？④ 删除某条测试档案
输入	自然语言问题（≤500 字符）+ 会话内工具结果
输出	中文回答：先结论数字，再给依据（工具统计或知识库片段编号），最后给建议
可用数据	H2 档案库（实验前 28 条历史档案）、rag/knowledge.json（10 个片段）
停止条件	① 回答通过程序检查；② 达到最大步数；③ 超过总时限；④ 等待确认被拒绝或超时；⑤ 发生不可恢复错误
成功标准	回答中的总数与高/中/低风险数量与 compute_risk_stats 逐项相等；引用知识库必须带片段编号；删除未经确认不执行

表 3-2 输入与预期结果

编号	提问	预期工具调用	预期结果
Q1	现在有多少份档案，风险分布如何?	compute_risk_stats(mode=all)	给出总数与三档计数，数字与工具一致
Q2	最近一条档案讲了什么，最严重的问题是什么?	list_reviews(limit=3) → get_review_detail(id)	指出档案 ID 与问题，不编造内容
Q3	知识库里文件上传有什么限制?	search_knowledge(q=…, k=3)	有结果时给出片段编号；无结果时说明资料不足
Q4	删除某条测试档案	delete_review(id) → 暂停等待确认	未确认不执行；确认后删除并回报
Q5	帮我查一下服务器磁盘占用	无工具可满足	明确说明无法执行，并建议可用问题

表 3-3 自动执行、必须确认与明确禁止

类别	内容

自动执行	list_reviews、compute_risk_stats、get_review_detail、search_knowledge——只读、幂等、无副作用
必须人工确认	delete_review：执行前展示档案 ID、创建时间、摘要和“不可恢复”提示；拒绝或 5 分钟未响应则不执行
明确禁止	执行模型生成的任意函数名、SQL 或 shell 命令；访问项目目录外文件；把 API Key 写入上下文或日志；批量删除；绕过确认直接写库；对写操作重复调用“碰运气”

表 3-4 程序预设与模型决定的边界

环节	由谁决定	实现位置
调用哪个工具、传什么参数	模型（输出 tool_calls）	QwenAgentModelClient
工具是否存在、参数是否合法	程序（白名单 + Schema 校验）	ToolRegistry、ArgumentValidator
工具执行与超时	程序（Future 限时）	AgentHarness.executeTool
是否继续循环、何时收尾	模型（无 tool_calls 即给出回答）	AgentHarness.loop
步数、总时限、重答次数	程序（到达即终止，模型无权延长）	AgentHarness、AnswerChecker
删除是否需要确认	程序（写工具强制挂起）	AgentRunStore
回答是否达标	程序（数字与引用核对）	AnswerChecker

操作步骤：① 先备份数据库 backend/data/ambiguity.mv.db 到 实验文档/TEST6/备份/；② 为验证删除流程，临时创建 2 条测试档案；③ 启动前后端，从首页进入“档案分析”。首页侧边栏已新增入口，如图 3-1。



图 3-1 首页：侧边栏新增“档案分析”入口（真实运行截图）

表 3-5 仓库与版本证据

项目	内容
仓库地址	https://github.com/Ventus-cn/AI_Request_Checker
实验 6 Commit	7fe4988（完整哈希 7fe49885cc8fc927bafde32925ccdae817ecd0ec），报告与截图见 a07d337、6a9611f
提交说明	实验 6：新增审查档案分析 Agent（工具调用、Harness、测试与运行日志）
推送结果	f5af077..7fe4988、7fe4988..a07d337、a07d337..6a9611f（main -> main）
代码路径	backend/src/main/java/com/example/ambiguity/agent 与 backend/src/test/java/com/example/ambiguity/agent
运行说明	实验文档/TEST6/运行说明.md

3.2 工具接口与参数约束

系统实现 5 个工具：4 个只读、1 个写操作。所有工具都由 Spring 注入后注册进 ToolRegistry，形成唯一白名单；模型给出的函数名不在白名单内会直接返回 ARG_INVALID，程序不会反射调用任意方法，也不执行模型生成的命令。

工具的最长等待时间为 5 秒；只读工具可重复调用且不产生副作用；delete_review 会修改数据，确认后只执行一次；若执行后出现异常则记为 STATE_UNKNOWN，要求人工核对，不自动重试。

表 3-6 工具清单

工具名	用途	输入	返回	超时	修改数据
list_reviews	列出档案摘要	limit 1–20；riskLevel 枚举	id、时间、摘要、风险、计数	5s	否
compute_risk_stats	风险统计	mode 枚举	total、high、medium、low、byType	5s	否
get_review_detail	单条档案详情	id（UUID）	档案字段与问题明细（截断）	5s	否
search_knowledge	检索知识库	q 2–100 字符；k 1–5	resultCount、chunks（含编号）	5s	否
delete_review	删除档案	id（UUID）	deleted、id	5s	是（需确认）

参数采用 OpenAI function 的 JSON Schema 结构，程序按 Schema 校验类型、范围、枚举、格式和多余字段。以 list_reviews 为例（其余见附录）：

```
{
  "type": "object",
  "properties": {
    "limit":     {"type": "integer", "minimum": 1, "maximum": 20, "default": 5},
```

```
    "riskLevel": {"type": "string", "enum": ["all","high","medium","low"], "default": "all"}
  },
  "required": [], "additionalProperties": false
}
```

表 3-7 参数校验规则

检查项	规则	失败反馈（回传模型）
工具名	必须命中 ToolRegistry 白名单	ARG_INVALID：未知工具，并列出可用工具
类型	integer 必须是整数，string 必须是字符串	ARG_INVALID：需要整数/字符串
范围	limit 1–20、k 1–5、q 2–100 字符	ARG_INVALID：不能大于 20，收到 999
枚举	riskLevel、mode 必须命中枚举	ARG_INVALID：只能取 all/high/...
格式	id 必须匹配 36 位 UUID	ARG_INVALID：id 格式不正确
多余字段	additionalProperties=false	ARG_INVALID：不支持的参数 xxx
执行超时	单次工具 5 秒	TIMEOUT：已停止等待，状态可能未知

接入 Agent 之前先做了直接测试：正确参数 list_reviews({"limit":3}) 返回 3 条真实档案；错误参数 list_reviews({"limit":999}) 被 ArgumentValidator 拒绝，回传 “list_reviews.limit 不能大于 20，收到：999”，查询没有执行。两组结果也固化为自动化测试（ToolRegistryTest 与 AgentHarnessTest）。

表 3-8 工具直接测试记录

编号	调用	预期	实际结果
T-1	list_reviews {"limit":3}	返回 3 条，按时间倒序	返回 3 条；后续在真实运行中再次验证
T-2	list_reviews {"limit":999}	拒绝，不执行查询	ARG_INVALID：不能大于 20，收到：999
T-3	get_review_detail {"id":"not-a-uuid"}	拒绝	ARG_INVALID：id 格式不正确
T-4	delete_all {}	未知工具拒绝	ARG_INVALID：未知工具，并列出 5 个可用工具

3.3 Agent 循环与状态

Agent 采用单轮循环：模型提出工具调用，程序负责校验、执行、回传和终止。循环图如下图 3-2，其中参数校验、人工确认和停止检查的位置都已标出。

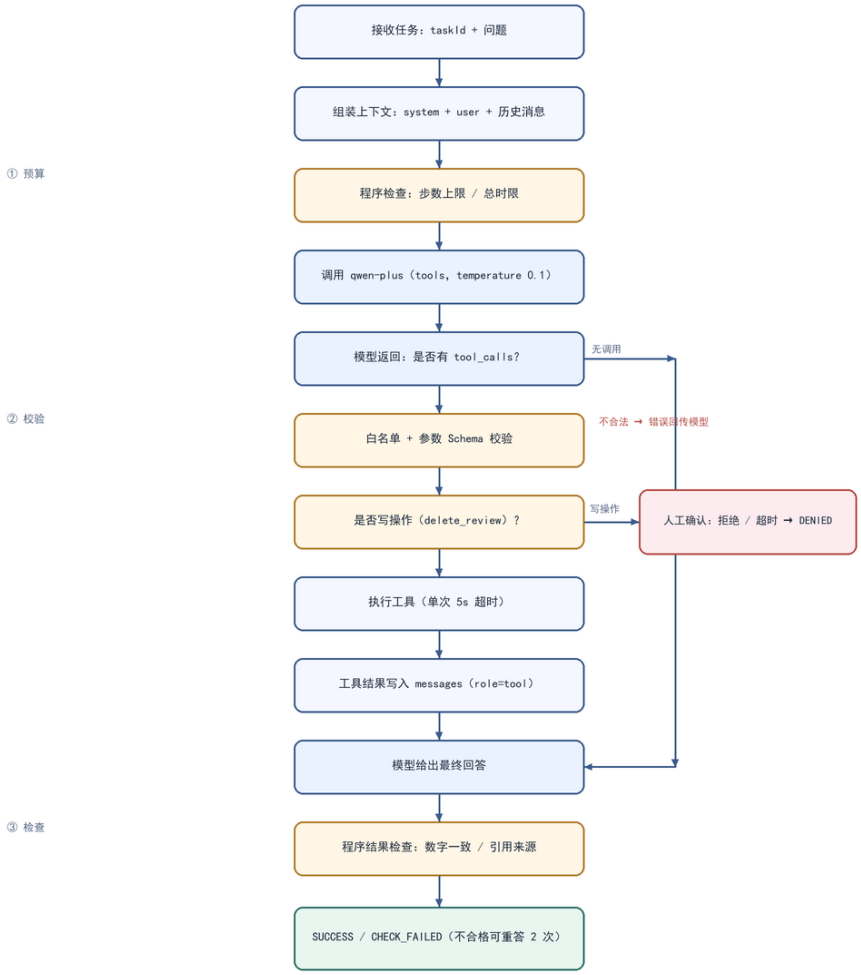


图 3-2 Agent 循环与状态（参数校验、人工确认、停止检查的位置）

调用请求与工具结果必须写回上下文，而不是只打印。assistant 的 tool_calls 原样回填，每个结果按 tool_call_id 对应一条 role=tool 消息：

```
[system]    角色、任务边界、可用工具与禁止事项
[user]      现在有多少份档案，风险分布如何？
[assistant] tool_calls=[{id:"call_1", function:{name:"compute_risk_stats",
                                                arguments:"{\"mode\":\"all\"}"}}]
[tool]      {"tool_call_id":"call_1","name":"compute_risk_stats",
             "content":"{\"total\":28,\"high\":21,\"medium\":6,\"low\":1,...}"}
[assistant] 目前共有 28 份档案，其中高风险 21 份、中风险 6 份、低风险 1 份……
```

一步定义为模型的一次响应：无论这次响应发起 1 个还是多个工具调用都只计一步；工具执行不单独计步，但计入总时限；单步最多 3 个工具调用，超出部分拒绝。这样计数可以避免模型用并行调用绕过步数限制。结果检查由程序执行：调用过 compute_risk_stats 时回答必须包含总数和高/中/低四个数字且与工具结果相

等；调用过 search_knowledge 且有结果时必须出现 KB 编号；没有检索却引用 KB 编号视为无依据引用，要求删除或重新检索。

表 3-9 程序级运行限制

参数	取值	到达后的行为
最大步数	6 步	终止并说明“已达最大步数，结论不完整”
模型超时	30 秒/次	本次调用失败，不再重试，返回 FAILED
工具超时	5 秒/次	向模型回传 TIMEOUT，允许换工具或说明原因
总时限	60 秒/次运行	下一步开始前检查，超时立即终止
重答次数	2 次	仍不合格则 CHECK_FAILED
单步工具数	3 个	超出部分拒绝并回报
确认有效期	5 分钟	超时不执行，任务失效

实际运行：从首页进入“档案分析”页（图 3-3），输入统计问题后点击“开始分析”。模型调用 compute_risk_stats，程序执行后把结果写回上下文，模型据此作答（图 3-4）。该次运行任务编号为 20261108-162656-e75830，工具返回总数 30、高风险 21、中风险 6、低风险 3，回答中的数字与之一致。

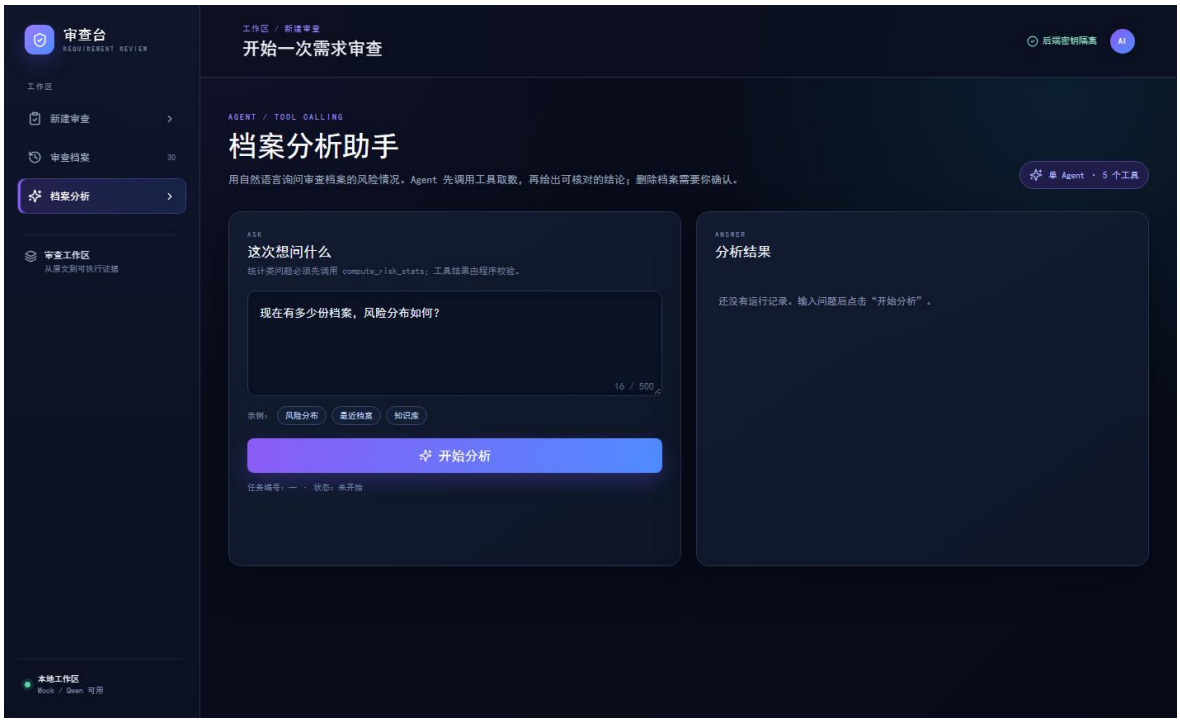


图 3-3 档案分析页：问题输入、示例问题与运行按钮

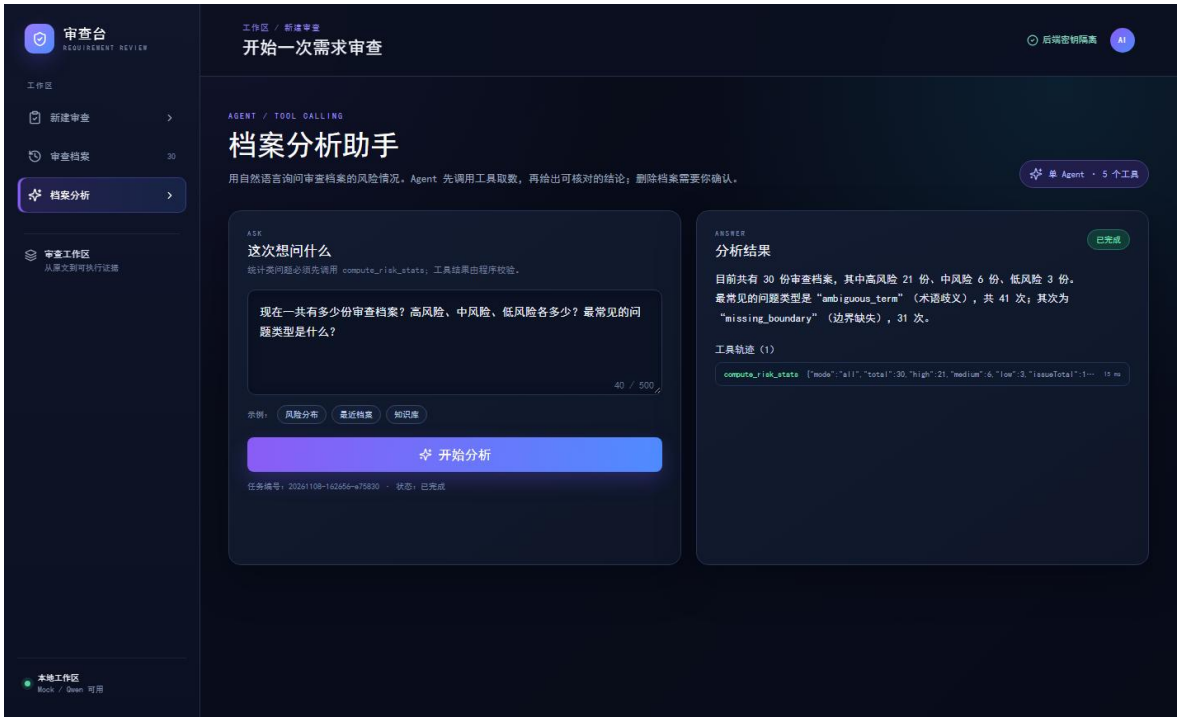


图 3-4 正常分析：回答给出 30 份档案与高/中/低风险数量，下方为工具轨迹

3.4 运行时 Harness 设计与实现

Harness 负责组织模型和工具之间的每一次交互：任务输入、上下文、执行、结果检查和日志分别由不同类承担，模块关系如图 3-5。

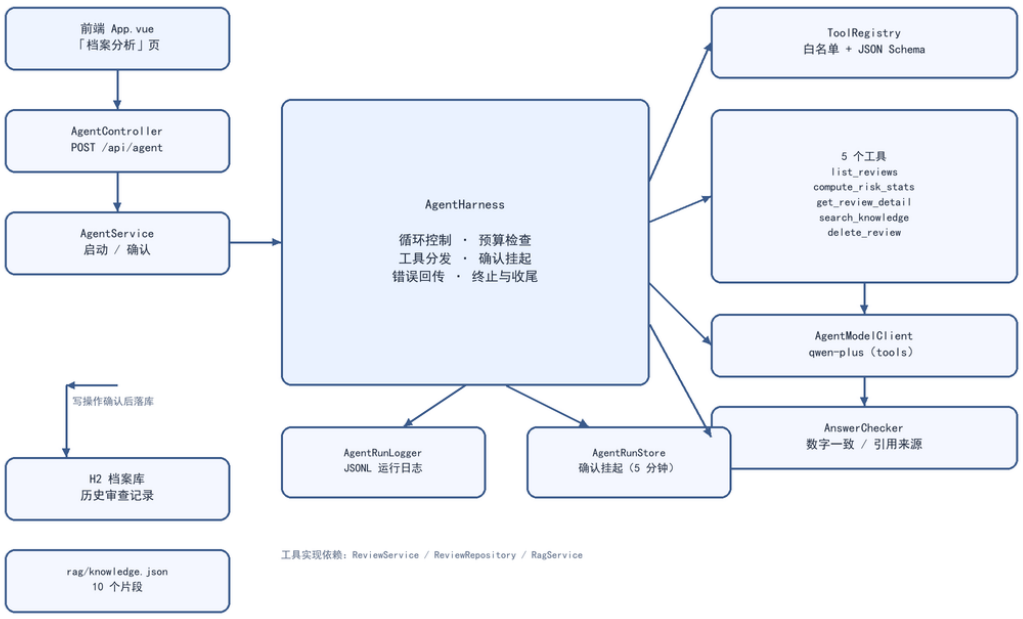


图 3-5 运行时 Harness 模块与依赖

表 3-10 Harness 模块职责

类	职责
AgentController	REST 入口，校验问题长度与确认参数，统一返回 400/404
AgentService	任务编排入口：启动运行、恢复确认
AgentHarness	循环控制、预算检查、工具分发、确认挂起与恢复、错误回传、终止
ToolRegistry	白名单：未命中的工具名直接拒绝
ArgumentValidator	按 JSON Schema 校验类型、范围、枚举、格式和多余字段
AgentModelClient	模型通道抽象；QwenAgentModelClient 调用 qwen-plus
AnswerChecker	数字一致性、知识库引用与无依据引用检查
AgentRunLogger	逐事件写 JSONL；参数与结果截断，密钥不落盘
AgentRunStore	保存等待确认的运行，5 分钟 TTL

上下文组织遵循“数据必须来自工具”的原则：系统提示只写角色、边界和输出要求，不放任何示例数字；历史工具结果按 tool_call_id 排列；单条工具结果进入上下文前截断到 2000 字符。确认流程被建模成显式状态：写操作不直接执行，Harness 先返回 NEED_CONFIRM 和影响说明，用户同意后才从断点继续，拒绝则直接以 DENIED 结束并明确“未删除任何档案”。

实际操作：在分析页输入“请删除档案 f1e24e91-011c-4519-b92d-bdd014c48706，这是一条测试档案”。模型调用 delete_review，弹出确认框（图 3-6），展示档案摘要和“删除后不可恢复”；点击“允许执行”后工具执行、模型收尾（图 3-7），档案从列表消失。

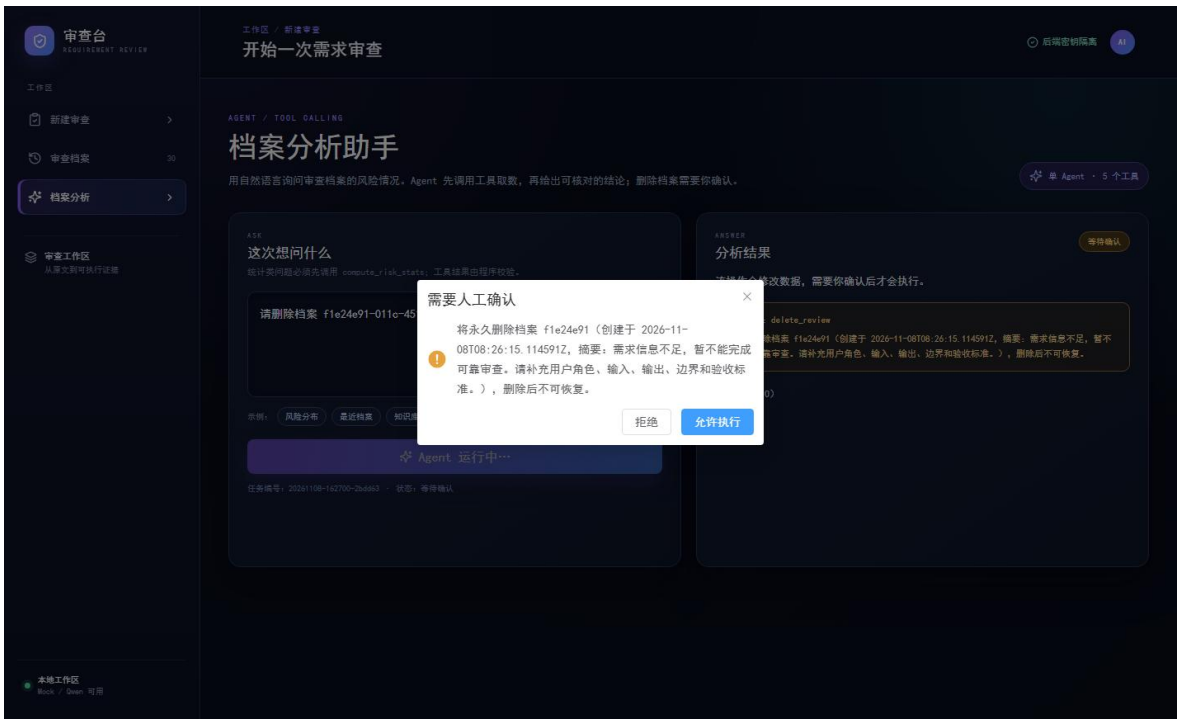


图 3-6 删除档案前的人工确认弹窗（展示影响，等待用户决定）

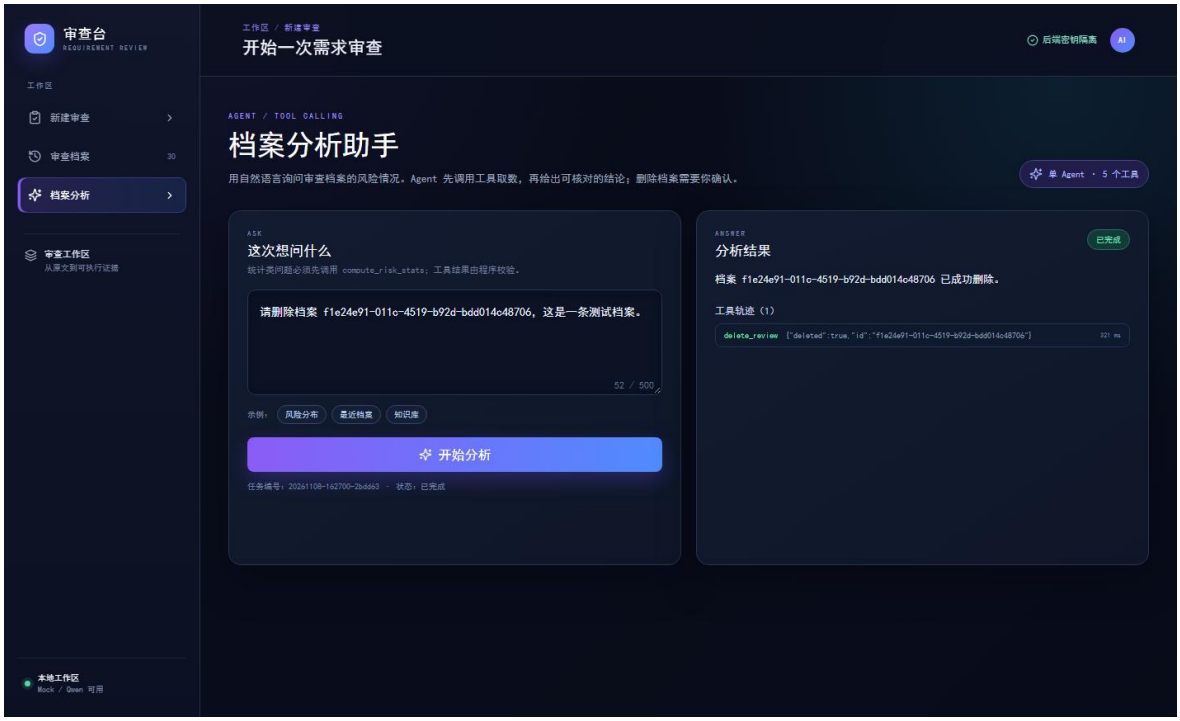


图 3-7 确认执行后：档案被删除，运行状态为“已完成”

3.5 失败处理与可观测性

每次运行生成任务编号，逐事件写入 backend/logs/agent-runs/<taskId>.jsonl。日志只记录工具名、参数摘要、结果摘要、错误类型、步数、耗时和最终状态；不记录 API Key、完整需求文本或完整外部响应。报告引用的 6 份日志同时复制到 实验文档/TEST6/运行日志/。

表 3-11 运行日志字段

字段	说明
taskId	yyyyMMdd-HHmmss-6 位随机，与前端展示一致
ts / step / phase	时间；步号；context/model/tool/confirm/check/finish
tool / args / result	工具名；参数摘要（≤120 字）；结果摘要（≤200 字）
status / errorType	ok 或 error；ARG_INVALID、NOT_FOUND、TOOL_EXCEPTION、TIMEOUT、STATE_UNKNOWN 等
durationMs / tokens	本事件耗时；模型返回的 prompt/completion token
finalStatus	SUCCESS、DENIED、STEP_LIMIT、TIMEOUT、CHECK_FAILED、FAILED

一次真实运行的日志（节选自任务 20261108-162558-c8c0a9）：

```
{"taskId":"20261108-162558-c8c0a9","step":0,"phase":"context","status":"ok",
 "tools":"compute_risk_stats,delete_review,get_review_detail,list_reviews,search_knowledge"}
{"taskId":"20261108-162558-c8c0a9","step":1,"phase":"model","status":"ok","durationMs":900}
{"taskId":"20261108-162558-c8c0a9","step":1,"phase":"tool","tool":"compute_risk_stats",
 "status":"ok","durationMs":27,"result":"{\"total\":28,\"high\":21,...}"}
{"taskId":"20261108-162558-c8c0a9","step":2,"phase":"model","status":"ok","durationMs":2486}
```

```
{"taskId":"20261108-162558-c8c0a9","step":2,"phase":"check","status":"ok","result":"ok"}
{"taskId":"20261108-162558-c8c0a9","step":2,"phase":"finish","status":"ok","finalStatus":"SUCCESS"}
```


表 3-12 错误分类与用户可见反馈

情形	内部状态	页面/回答
参数错误	ARG_INVALID 回传模型	模型换参数重试；仍失败则说明参数不合法并停止
工具异常/记录不存在	TOOL_EXCEPTION / NOT_FOUND	说明查不到该档案，不编造数据
工具或模型超时	TIMEOUT	已停止等待；后台可能仍在执行，状态未知，请核对
达到步数上限	STEP_LIMIT	结论不完整，并给出已获得的工具结果
用户拒绝确认	DENIED	已取消，未删除任何档案
写操作执行后异常	STATE_UNKNOWN	结果不确定，请到列表核对；不自动重试
结果校验失败	CHECK_FAILED	统计数字与工具结果不一致，已终止

超时的实际取消能力：程序用 Future 限时，超时后调用 cancel(true) 中断线程并停止等待，但这不代表后台数据库操作一定已回滚；因此日志标记 TIMEOUT，回答提示“状态未知，请核对”。拒绝确认的演练：同样输入删除请求，在弹窗中点击“拒绝”，运行以 DENIED 结束（图 3-8），档案仍可查询。

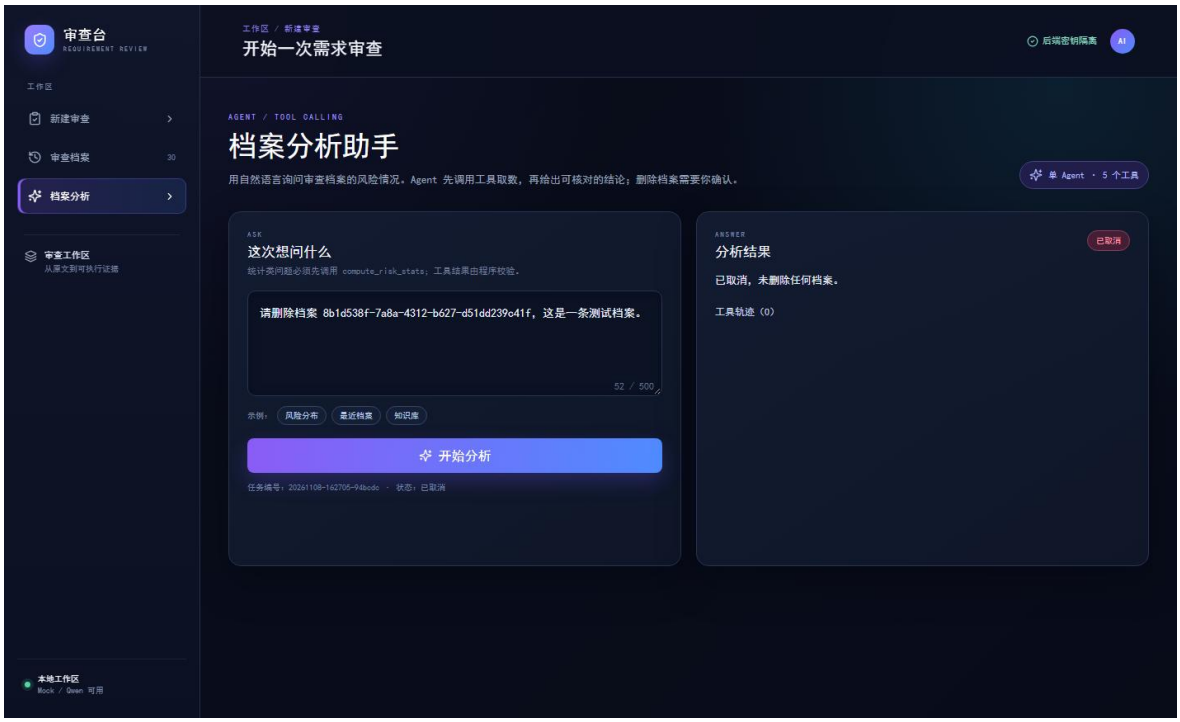


图 3-8 拒绝确认：状态为“已取消”，回答说明未删除任何档案

3.6 测试与结果分析

后端共 33 个自动化测试全部通过，其中本实验新增 17 个：AgentHarnessTest 11 个（模型用测试桩，覆盖失败与边界）、ToolRegistryTest 6 个（白名单与参数 Schema）；原有 16 个测试不受影响。除自动化测试外，真实流程执行 5 次，全部调用 qwen-plus 与实际工具。

表 3-13 五类测试覆盖与结果

编号	类别	输入/操作	实际结果
TA-01	正常完成（真实模型）	询问档案风险分布	SUCCESS；调用 compute_risk_stats；回答 30 份、高 21、中 6、低 3，与工具一致
TA-02	参数错误（测试桩）	模型传 limit=999	程序拒绝并回传 ARG_INVALID，查询未执行；模型改口径后结束
TA-03	工具异常（测试桩）	查询不存在的 UUID	返回 NOT_FOUND，回答说明查不到，不编造
TA-04	步数上限（测试桩）	max-steps=1，模型继续请求工具	STEP_LIMIT，回答说明结论不完整
TA-05	时间限制（测试桩）	慢工具 + 50ms 工具超时	TIMEOUT 回传模型，运行继续并收尾
TA-06	人工确认-同意（真实）	删除测试档案并确认	执行删除，档案从列表消失（图 3-7）
TA-07	人工确认-拒绝（真实）	删除测试档案并拒绝	DENIED，回答“未删除”，档案仍可查询（图 3-8）
TA-08	结果校验（测试桩）	回答写错数字 / 无依据引用	触发重答；仍错则 CHECK_FAILED；引用被要求删除
TA-09	未知工具（测试桩）	调用 delete_all	ARG_INVALID：未知工具，拒绝执行

表 3-14 真实运行记录

任务编号	问题	工具调用	最终状态
20261108-162656-e75830	档案总数与风险分布	compute_risk_stats	SUCCESS
20261108-162700-2bdd63	删除测试档案 f1e24e91	delete_review（确认后）	SUCCESS
20261108-162705-94bcdc	删除测试档案 8b1d538f	delete_review（拒绝）	DENIED
20261108-162818-968b42	知识库文件上传限制	search_knowledge（0 条）	SUCCESS（资料不足）
20261108-162820-5fcb93	最近 3 条档案摘要	list_reviews(limit=3)	SUCCESS

说明：为验证删除流程，实验前临时创建了 2 条测试档案，因此统计运行显示 30 份；确认删除后剩 29 份，被拒绝删除的一条保留，档案列表如图 3-9。



图 3-9 审查档案列表：被删除的档案不再出现，拒绝删除的档案仍在

表 3-15 开发与测试中发现的问题

编号	问题	处理
P-1	对 Map<?,?> 调用 getOrDefault 触发泛型捕获编译错误	先取 Object 再判空，重新编译通过
P-2	lambda 捕获被重新赋值的局部变量，编译报“必须是最终变量”	改用独立变量承接解析结果
P-3	测试 Schema 的 riskLevel 未写 default，断言失败	补默认值后通过
P-4	单例 Harness 的预算字段被前一个用例改小，后续用例误判超时	每个用例前重置预算
P-5	target/test-classes 残留旧 class，出现 NoClassDefFoundError	执行 mvn clean 后恢复
P-6	真实模型未检索却附带 [KB-003] 编号	补充“无检索不得引用”的检查规则
P-7	提示词要求“先说明再调用”，模型改为反问用户要 ID，删除流程走不通	改为用户明确要求后直接调用，由程序弹出确认
P-8	知识库按整段汉字匹配，“文件上传限制”检索 0 条（未修复）	模型按规则回答“资料不足”不编造；列入改进计划

测试覆盖了要求的 5 类情况，人工确认分别验证了同意与拒绝；正常流程实际调用了模型和工具，异常与边界用测试桩稳定复现。从定位看，问题分别落在参数（P-3）、工具（P-5、P-8）、检查规则（P-6）、控制流程（P-4）和模型决策（P-7）五个层面，说明“让模型自己保证正确”并不可靠，程序侧的校验和状态管理才是可测试的部分。

Agent 与运行时 Harness 已用于个人软件：入口在侧边栏“档案分析”，接口为 POST /api/agent/runs 与 POST /api/agent/runs/{taskId}/confirm，代码位于 backend/src/main/java/com/example/ambiguity/agent，测试位于 backend/src/test/java/com/example/ambiguity/agent，运行说明见 实验文档/TEST6/运行说明.md，对应 Commit 为 7fe4988。

当前局限与改进计划：知识库仍是整段汉字匹配，口语化提问召回不足，计划改为二字词或向量检索；上下文只做截断，计划增加摘要压缩；工具串行执行，计划利用并行调用；前端仍是单文件页面，计划把“档案分析”拆成独立组件；多人使用时需要补充鉴权与审计落库。

4. 实验小结

本次实验在 AI 需求歧义审查器上完成了“审查档案分析助手”：5 个白名单工具、单 Agent 循环、运行时 Harness、人工确认、结果检查和 JSONL 运行日志，并通过 33 个自动化测试和 5 次真实运行验证。Agent 已经作为产品的一个页面和接口使用，不是独立练习。

实现过程中体会最深的是三点。第一，能用程序做的事不要交给提示词：白名单、Schema、步数、超时和确认流程一旦写进代码，模型就无法绕过，测试也才有稳定的断言对象。第二，人工确认必须建模成显式状态，而不是让模型在回答里“请用户确认”，否则无法保证写操作真的没有执行。第三，日志和结果检查是排错的核心：真实运行中出现过无依据引用和检索 0 条的情况，正是日志里的阶段、错误类型和检查结果让问题可定位。

当前局限也很明确：知识库仍用整段汉字匹配，口语化提问召回不足；上下文只做了截断，没有摘要压缩；工具串行执行，尚未利用并行调用；前端仍是单文件页面结构。后续计划把检索改为二字词或向量匹配、为长上下文增加摘要、把“档案分析”拆成独立组件，并在需要多人使用时补充鉴权和审计落库。

附录 工具参数定义与运行说明

5 个工具的完整参数定义（OpenAI function.parameters 结构）：

```
list_reviews
{"type":"object","properties":{
  "limit":{"type":"integer","minimum":1,"maximum":20,"default":5},
  "riskLevel":{"type":"string","enum":["all","high","medium","low"],"default":"all"}},
 "required":[],"additionalProperties":false}


compute_risk_stats
{"type":"object","properties":{
  "mode":{"type":"string","enum":["all","全面审查","可测试性","安全与权限"],"default":"all"}},
```

```
 "required":[],"additionalProperties":false}


get_review_detail / delete_review
{"type":"object","properties":{
  "id":{"type":"string","pattern":"^[0-9a-fA-F-]{36}$"}},
 "required":["id"],"additionalProperties":false}


search_knowledge
{"type":"object","properties":{
  "q":{"type":"string","minLength":2,"maxLength":100},
  "k":{"type":"integer","minimum":1,"maximum":5,"default":3}},
 "required":["q"],"additionalProperties":false}
```

运行方式：在 backend/.env.local 配置 AI_MODE=qwen 、 DASHSCOPE_API_KEY 、 QWEN_MODEL=qwen-plus（该文件不入库），执行 backend/run-local.ps1 与 frontend 的 npm run dev ， 浏览器打开 http://localhost:5173 。 可调参数： AGENT_MAX_STEPS=6 、 AGENT_TOTAL_TIMEOUT_MS=60000 、 AGENT_TOOL_TIMEOUT_MS=5000 、 AGENT_MAX_ANSWER_RETRIES=2 、 AGENT_CONFIRM_TTL_MS=300000 、 AGENT_LOG_DIR=./logs/agent-runs。